MINERAÇÃO DE DADOS NO SUS: PADRÕES DE USO DE MEDICAMENTOS E TERAPIAS NA SAÚDE PÚBLICA

Diego Luiz Oliveira (UEPG) E-mail: diego.oliveira@uepg.br
Maria Salete Marcon Gomes Vaz (UEPG) E-mail: salete@uepg.br

Resumo: Este artigo tem como objetivo aplicar técnicas de mineração de dados para identificar padrões no uso de medicamentos e terapias registrados no Sistema Único de Saúde (SUS), com base em dados ambulatoriais do estado do Paraná no ano de 2023. A análise parte da coleta de dados públicos disponibilizados pelo DATASUS, especificamente da base do SIA/SUS, com foco em procedimentos associados a tratamentos clínicos. Após o pré-processamento dos dados e a aplicação de filtros com base no SIGTAP e CID-10, foram realizadas análises de frequência e agrupamento com o uso de algoritmos de aprendizado de máquina. O estudo visa contribuir para a compreensão dos perfis de atendimento e auxiliar na gestão eficiente dos recursos do SUS.

Palavras-chave: mineração de dados; SUS; SIA/SUS; medicamentos; terapias; clustering.

DATA MINING IN THE SUS: PATTERNS OF MEDICATION AND THERAPY USE IN PUBLIC HEALTH

Abstract: This paper aims to apply data mining techniques to identify patterns in the use of medications and therapies recorded in the Brazilian Unified Health System (SUS), based on outpatient data from the state of Paraná for the year 2023. The analysis is grounded on public data provided by DATASUS, specifically from the SIA/SUS database, focusing on procedures related to clinical treatments. After data preprocessing and the application of filters based on SIGTAP and ICD-10, frequency and clustering analyses were performed using machine learning algorithms. The study seeks to contribute to the understanding of healthcare service profiles and to support the efficient management of SUS resources.

Keywords: data mining; SUS; SIA/SUS; medications; therapies; clustering.

1. Introdução

A crescente digitalização dos serviços de saúde tem possibilitado o armazenamento e a disponibilização de grandes volumes de dados relativos a atendimentos, procedimentos clínicos e diagnósticos realizados na rede pública. No Brasil, o Sistema Único de Saúde (SUS), por meio do Departamento de Informática do SUS (DATASUS), disponibiliza essas informações de forma pública e estruturada, favorecendo o desenvolvimento de análises exploratórias e preditivas com o suporte de ferramentas computacionais (BRASIL, 2025).

Nesse cenário, as técnicas de mineração de dados (data mining) destacam-se como instrumentos eficazes para a extração de padrões ocultos, associações e tendências relevantes nos bancos de dados em saúde, especialmente no que se refere ao uso de medicamentos e terapias ambulatoriais (HAN; KAMBER; PEI, 2012). Essas técnicas possibilitam transformar dados brutos em conhecimento útil, como a identificação de diagnósticos recorrentes, a detecção de procedimentos com alta frequência de uso, a caracterização de perfis de pacientes com base em variáveis demográficas e clínicas, bem como o mapeamento de associações entre doenças e tratamentos. Esse tipo de conhecimento pode subsidiar políticas públicas, orientar ações estratégicas e aperfeiçoar os processos de gestão do sistema de saúde (SILVA; PERES; BOSCARIOLI, 2016).

A análise automatizada torna-se ainda mais necessária diante da amplitude e da complexidade das bases de dados do SUS, que registram milhões de atendimentos mensais. Métodos tradicionais de avaliação não são suficientes para lidar com esse volume de informações de forma eficiente, tornando indispensável o uso de algoritmos e modelos estatísticos para detectar padrões de uso, desperdícios ou concentrações de procedimentos terapêuticos (LAVRAČ, 1999; AMARAL, 2019).

A escolha deste tema justifica-se pela relevância em compreender como os recursos terapêuticos estão sendo aplicados, quais doenças apresentam maior consumo de medicamentos e quais perfis de pacientes predominam nesses tratamentos. Esse entendimento pode favorecer melhorias significativas no planejamento em saúde, na alocação de recursos e na definição de estratégias preventivas e assistenciais (WHO, 2022).

Diante disso, o presente trabalho pretende analisar os dados do SUS para identificar padrões de uso de medicamentos e terapias no sistema público de saúde, utilizando técnicas de mineração de dados. Os objetivos específicos incluem: (i) levantar e preparar um conjunto de dados relevantes extraídos do SIA/SUS; (ii) aplicar métodos de mineração de dados para detecção de padrões e tendências; (iii) identificar possíveis excessos, desperdícios ou concentração de procedimentos; e (iv) propor melhorias para uma alocação mais eficiente dos recursos com base nos padrões identificados.

2. Fundamentação Teórica

Este capítulo apresenta os principais conceitos e fundamentos que sustentam o desenvolvimento do trabalho, abordando a mineração de dados e suas etapas, o papel do DATASUS na organização das informações de saúde pública e a descrição das bases utilizadas na análise. Também são discutidos estudos relacionados que evidenciam a aplicação de técnicas semelhantes em contextos de saúde.

A mineração de dados, também conhecida como data mining, integra o processo de descoberta de conhecimento em bases de dados (KDD – Knowledge Discovery in Databases) e reúne métodos e algoritmos capazes de explorar grandes volumes de dados para revelar padrões, correlações e tendências relevantes para a tomada de decisão (SILVA; PERES; BOSCARIOLI, 2016). Para Amaral (2019), esse processo consiste em explorar e analisar dados extensos em busca de previsões, erros, associações e outros elementos que possam gerar conhecimento aplicado. Essa abordagem mostra-se particularmente eficaz em contextos com grandes volumes de dados, nos quais a análise manual se torna inviável.

As etapas da mineração de dados iniciam-se com a coleta de dados relevantes de fontes diversas, como bancos de dados, registros de atendimento e transações. De acordo com Márquez-Vera et al. (2013), essa fase consiste na obtenção dos dados que serão analisados posteriormente. Em seguida, ocorre o pré-processamento, etapa fundamental que envolve a limpeza, correção de inconsistências, eliminação de redundâncias e preenchimento de lacunas, preparando os dados para a análise. Essa etapa é importante para garantir a qualidade dos dados a serem analisados (AWARI, 2025).

Posteriormente, tem-se a fase de exploração, onde algoritmos e técnicas estatísticas são aplicados, frequentemente acompanhados de representações visuais, que facilitam a identificação de padrões e comportamentos nos dados (ROSSINI ET AL., 2018). Por fim,

com base nas descobertas dessa análise exploratória, os dados são modelados utilizando algoritmos de aprendizado de máquina, com foco em classificações, agrupamentos ou predições automatizadas, como evidenciado em estudos que relacionam as técnicas de aprendizado de máquina à mineração de dados (CARVALHO, 2014).

Entre as técnicas de mineração de dados, destacam-se três abordagens relevantes para este estudo. A clusterização K-means é um algoritmo iterativo amplamente utilizado que visa particionar um conjunto de dados em k clusters distintos. Ele agrupa os pontos de dados em torno de centróides, que representam o "centro" de cada grupo, buscando minimizar a soma das distâncias quadradas entre os pontos e seus respectivos centróides. Essa abordagem torna o k-means eficiente e simples, especialmente adequado para segmentação de grandes volumes de dados, como no perfilamento de clientes ou na análise de dados em saúde (PONTES; SANTANA, 2020; IBM, 2024).

Outro método empregado são as árvores de decisão do tipo CART, modelos preditivos baseados em segmentações binárias dos dados, que produzem resultados interpretáveis e que podem ser aplicados em tarefas de classificação e regressão. Garcia (2003) enfatiza a utilização do CART na área da saúde, demonstrando sua capacidade de lidar com dados ruidosos e incompletos para classificação de autorizações hospitalares, apoiando decisões clínicas e administrativas no SUS.

Já a técnica Apriori, utilizada para mineração de regras de associação, visa identificar conjuntos frequentes de itens em grandes bases transacionais. Segundo Silva (2004), o algoritmo procede em duas fases principais: inicialmente, identifica todos os itens que aparecem com frequência mínima suficiente nas transações e, posteriormente, gera combinações maiores desses conjuntos, descartando aqueles que não satisfazem o critério de frequência. Esse processo limita o espaço de busca e garante a eficiência do método, sendo fundamental para a descoberta de padrões relevantes que apoiam a tomada de decisão em diversos contextos, incluindo aplicações na área da saúde.

No âmbito da saúde pública brasileira, o Sistema Único de Saúde (SUS) gera diariamente uma enorme quantidade de registros referentes a atendimentos, diagnósticos, procedimentos e internações. O Departamento de Informática do SUS (DATASUS), criado em 1991, centraliza e organiza essas informações em bases de dados padronizadas e públicas (BRASIL, 2025). Estima-se, por exemplo, que entre 2000 e 2013 tenham sido registrados aproximadamente 164 milhões de internações, 35 milhões de nascimentos, 12 milhões de óbitos e mais de 20 bilhões de procedimentos ambulatoriais (UNA-SUS, 2015), evidenciando a dimensão e o potencial dessas bases para análise.

Entre os sistemas disponibilizados pelo DATASUS, destaca-se o SIA/SUS – Sistema de Informações Ambulatoriais, que registra procedimentos como consultas médicas, exames, terapias, aplicações de medicamentos e vacinas. Essa base contém informações padronizadas, incluindo códigos de procedimentos, diagnósticos, idade, sexo do paciente e tipo de financiamento, sendo amplamente utilizada em estudos epidemiológicos e de planejamento em saúde (BRASIL, 2025). No presente trabalho, o SIA/SUS constitui a base principal para a análise dos padrões de uso de medicamentos e terapias.

Outro sistema relevante é o SIH/SUS – Sistema de Informações Hospitalares, voltado para registros de internações hospitalares e que abrange informações sobre diagnósticos, procedimentos, tempo de internação e desfechos clínicos. Embora não explorado diretamente neste trabalho, o SIH/SUS complementa o panorama da utilização de recursos de saúde no país (PORTELA ET AL., 1997). Além disso, o CNES – Cadastro Nacional de Estabelecimentos de Saúde reúne dados sobre todas as unidades de saúde vinculadas ao SUS, como infraestrutura, recursos humanos e serviços disponíveis (IBGE, 2025).

Para a correta interpretação dos dados extraídos dessas bases, é fundamental o uso do SIGTAP – Sistema de Gerenciamento da Tabela de Procedimentos, Medicamentos e OPM do SUS. Essa tabela oficial padroniza os itens financiados pelo sistema público de saúde, associando procedimentos a diagnósticos e determinando suas características técnicas (BRASIL, 2025). Neste estudo, o SIGTAP foi utilizado como filtro de validação para garantir que somente registros efetivamente relacionados a medicamentos e terapias fossem analisados, assegurando maior precisão na abordagem adotada.

Nesse contexto, destaca-se o trabalho de Stemmer (2023), que desenvolveu uma ferramenta interativa para análise e mineração de dados de mortalidade por suicídio no Brasil, a partir de bases do DATASUS, especialmente o Sistema de Informações sobre Mortalidade (SIM). Seu estudo segue as diretrizes da metodologia CRISP-DM, contemplando desde a compreensão dos dados até sua modelagem e avaliação. Após o pré-processamento e enriquecimento das bases (com dados do IBGE, CNES e SIM), foram aplicadas técnicas de clusterização hierárquica, com foco no método complete linkage, avaliadas por métricas internas como o índice de silhueta e o índice de Calinski-Harabasz. A partir da análise, o autor identificou perfis distintos de indivíduos vítimas de suicídio, agrupados com base em características sociodemográficas (como idade, sexo, estado civil e escolaridade) e circunstâncias da ocorrência (local, método utilizado, período do dia, entre outras).

A ferramenta desenvolvida utiliza tecnologias como Python, PySUS e o framework Streamlit, possibilitando a visualização interativa de dados e a geração de mapas, gráficos e dendrogramas, o que facilita o entendimento de informações complexas mesmo por usuários não especialistas. O reuso dos dados públicos do DATASUS neste contexto comprova sua versatilidade, bem como a importância de ferramentas de apoio à análise exploratória e à tomada de decisão baseada em evidências no SUS.

Dessa forma, o trabalho de Stemmer (2023) não somente comprova a viabilidade técnica da aplicação de mineração de dados em saúde pública, como também serve de referência metodológica e tecnológica para estudos que visem compreender o uso dos recursos do SUS, incluindo a análise de padrões no uso de medicamentos, terapias, procedimentos ambulatoriais e hospitalares. A integração entre bases padronizadas do DATASUS, aprendizado de máquina não supervisionado e visualização interativa torna-se, assim, uma abordagem robusta e replicável para a análise de outros fenômenos de interesse na saúde coletiva.

3. Materiais e Métodos

Este estudo caracteriza-se como uma pesquisa aplicada, com abordagem quantitativa e natureza exploratória. A pesquisa aplicada busca solucionar problemas práticos com base em

conhecimento científico, enquanto a abordagem quantitativa permite lidar com grandes volumes de dados de forma objetiva. O caráter exploratório justifica-se pela intenção de identificar padrões ainda pouco documentados no uso de medicamentos e terapias no Sistema Único de Saúde (SUS), a partir de registros reais.

Os dados utilizados foram extraídos do Sistema de Informações Ambulatoriais do SUS (SIA/SUS), disponível publicamente por meio do DATASUS, tendo como escopo o estado do Paraná ao longo dos 12 meses do ano de 2023. A coleta foi realizada na linguagem R, utilizando o pacote microdatasus, que viabiliza o download e a leitura estruturada dos arquivos diretamente do sistema. As análises foram conduzidas no ambiente RStudio, com o suporte de pacotes especializados: dplyr, tidyr e stringr no pré-processamento; ggplot2 e scales nas visualizações.

O processo de preparação dos dados iniciou-se com o download dos arquivos mensais do SIA/SUS, referentes ao estado do Paraná em 2023. Cada mês foi salvo separadamente, depois agrupado por semestre e, por fim, unificado em uma única base, totalizando 40.335.101 registros e 82 colunas. Em razão de limitações computacionais, foi necessário dividir o processamento por semestre. Para cada período, criou-se uma coluna de data (mes_competencia) a partir da variável PA_CMP, representando a competência no formato ano-mês. A base do primeiro semestre totalizou 19.602.136 registros, enquanto a do segundo semestre somou 20.732.965, ambas com 83 colunas.

Em seguida, cada base semestral foi integrada com a tabela SIGTAP (Sistema de Gerenciamento da Tabela de Procedimentos, Medicamentos e OPM do SUS), responsável pela padronização dos procedimentos financiados pelo SUS, possibilitando a incorporação das colunas de grupo (CO_GRUPO), subgrupo (CO_SUB_GRUPO) e forma de organização (CO_FORMA_ORGANIZACAO), essenciais para as análises posteriores. Os dados foram então filtrados para manter apenas os procedimentos pertencentes aos grupos relevantes para os objetivos do estudo: 03 – Procedimentos clínicos, 06 – Medicamentos e 08 – Ações complementares da atenção à saúde. Posteriormente, realizou-se o cruzamento com a tabela de Classificação Internacional de Doenças (CID-10) disponibilizada pelo SIGTAP, permitindo reter apenas os registros com códigos válidos, excluindo entradas ausentes, genéricas ou inválidas (como “0000”, NA ou vazios). Após essa filtragem, a base do primeiro semestre ficou com 4.516.824 registros, e a do segundo com 4.856.417, ambas agora com 91 colunas.

Dado que o volume de registros foi consideravelmente reduzido, tornou-se viável consolidar os dois semestres em uma única base de dados. Nesse processo, identificaram-se registros referentes a meses de 2022, os quais foram eliminados, garantindo que a base final contivesse exclusivamente dados de janeiro a dezembro de 2023. Na sequência, foram removidas colunas redundantes, duplicadas ou sem relevância para os objetivos da pesquisa, como identificadores administrativos, campos técnicos ou variáveis com valor constante. Por fim, foram excluídos os registros com quantidade aprovada igual a zero (PA_QTDAPR = 0) ou valor aprovado menor, ou igual a zero (PA_VALAPR ≤ 0), por representarem inconsistências de registros, procedimentos não efetivados ou atendimentos não validados. Esta última etapa assegurou maior integridade e representatividade à base analítica final, sendo composta por 4.685.717 registros e 20 variáveis, constituindo a principal fonte para as análises

exploratórias e para a aplicação das técnicas de mineração de dados, as quais são detalhadas a seguir.

A técnica de agrupamento (clustering) foi implementada com o algoritmo K-means, aplicado sobre uma amostra aleatória de 10 mil registros da base consolidada, com o objetivo de identificar perfis semelhantes de pacientes. Foram utilizadas como variáveis preditoras a idade, o sexo (codificado como binário: 0 = feminino, 1 = masculino) e o código da doença (CID-10, convertido em fator numérico). As variáveis foram previamente padronizadas (escalonamento z-score) para garantir uma base comum de comparação. A definição do número ideal de clusters foi realizada com o auxílio do método do cotovelo (WSS – Within-Cluster Sum of Squares), implementado por meio da função fviz_nbclust() do pacote factoextra, sendo adotado o valor de k = 3 clusters. Após a clusterização, os agrupamentos foram analisados por meio de gráficos de dispersão e histogramas, com destaque para a distribuição dos CIDs e procedimentos mais frequentes em cada grupo, além da análise cruzada por sexo e faixa etária.

Na etapa de classificação supervisionada, foi empregada uma árvore de decisão do tipo CART (Classification and Regression Tree), utilizando a função rpart() do pacote rpart. O modelo foi treinado para prever o procedimento realizado a partir das variáveis preditoras: idade, sexo e CID-10 principal. Inicialmente, foram selecionados os 8 códigos CID mais frequentes e os 8 procedimentos mais realizados, filtrando-se a base de dados para conter apenas essas categorias. A base foi dividida em subconjuntos de treino (70%) e teste (30%) de forma aleatória. A visualização da árvore final foi realizada com o pacote rpart.plot, com ajustes para melhor legibilidade dos rótulos.

Por fim, foi realizada a mineração de regras de associação com o algoritmo Apriori, por meio do pacote arules. A base utilizada foi composta pelos 10 CIDs e 10 procedimentos mais frequentes no ano, totalizando cerca de 300 mil transações após a amostragem. Os dados foram estruturados no formato de transações, representando pares entre o código da doença (CID-10) e o procedimento realizado. Além disso, foram definidos limiares mínimos de suporte dinâmico (ajustado conforme o tamanho da amostra) e confiança de 0,1 para a geração das regras, ordenadas com base no lift (grau de associação).

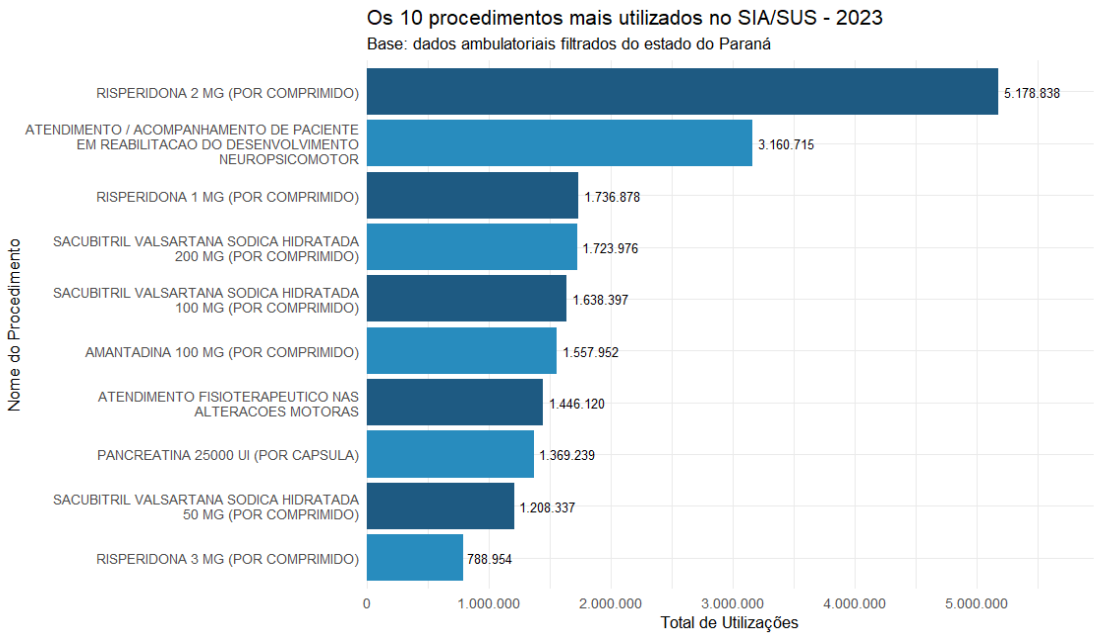
4. Resultados e Discussão

O processamento e a análise do conjunto de dados filtrado, composto por 4.685.717 registros de atendimentos ambulatoriais realizados no estado do Paraná ao longo de 2023, permitiram identificar padrões relevantes no uso de medicamentos, terapias e procedimentos clínicos no SUS. Os resultados foram organizados em três eixos: análise exploratória e descritiva, segmentação de pacientes por agrupamentos (K-means) e técnicas de predição e associação entre diagnósticos (CID-10) e procedimentos (SIGTAP).

4.1. Análise Exploratória e Descritiva

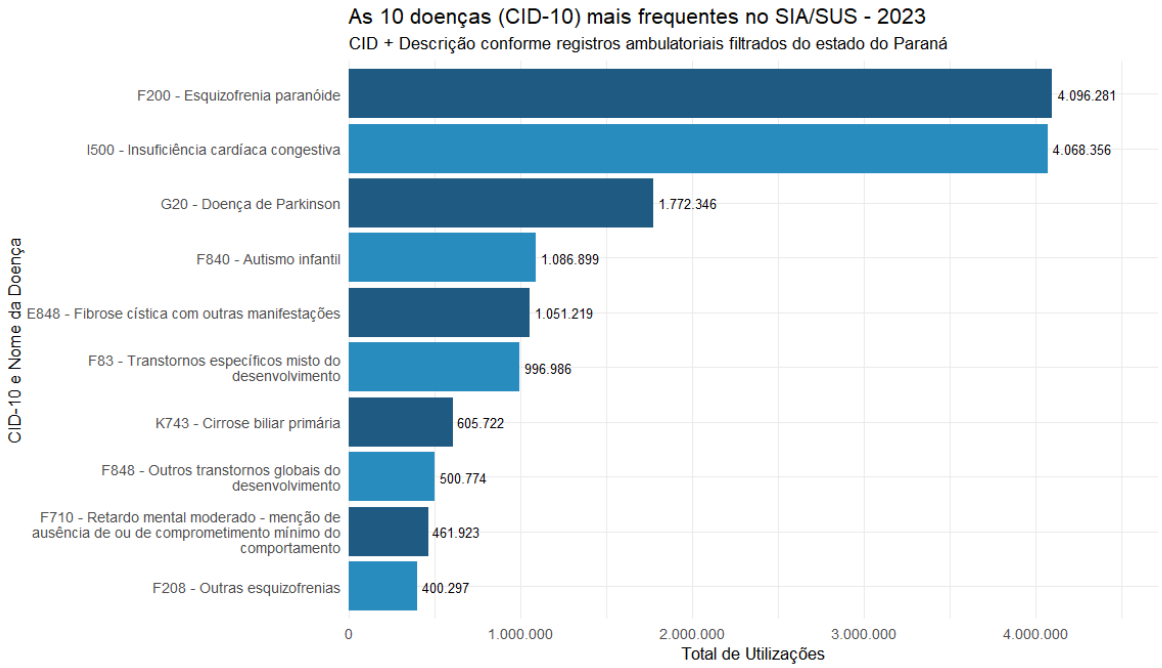
A análise inicial buscou identificar os procedimentos mais frequentemente realizados durante o ano. Entre eles, destaca-se o uso da Risperidona 2 mg (miligrama), com mais de 5,1 milhões de utilizações, refletindo uma elevada prevalência de tratamentos voltados à saúde mental.

Figura 1 - Os 10 procedimentos mais utilizados no SIA/SUS - 2023



Fonte: O autor

Figura 2 - As 10 doenças (CID-10) mais frequentes no SIA/SUS - 2023



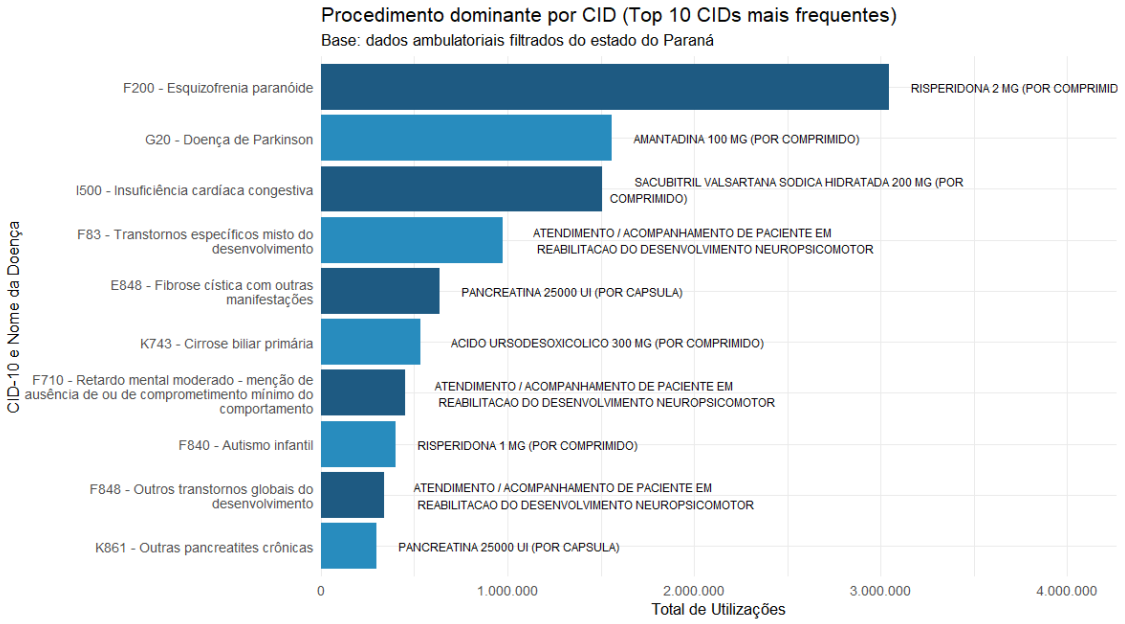
Fonte: O autor

O volume está diretamente relacionado ao diagnóstico mais recorrente: F20.0 – Esquizofrenia paranóide, que contabilizou cerca de 4,1 milhões de registros. Na sequência, destaca-se também o procedimento de Atendimento/Acompanhamento em Reabilitação do Desenvolvimento Neuropsicomotor, evidenciando uma demanda expressiva por terapias de

reabilitação cognitiva e neurológica. Esses achados são apresentados na Figura 1 (procedimentos) e na Figura 2 (principais CIDs).

A associação entre os principais diagnósticos e os procedimentos correspondentes é aprofundada na Figura 3, que mostra, por exemplo, a relação entre a insuficiência cardíaca congestiva (I50.0) e a prescrição de Sacubitril Valsartana Sódica Hidratada 200 mg, além de destacar o uso de Pancreatina em casos de Fibrose Cística (E84.8) e Amantadina na Doença de Parkinson (G20). Esses cruzamentos reforçam a consistência clínica dos dados analisados, demonstrando que há uma forte correspondência entre o tipo de CID registrado e o tratamento ambulatorial aprovado.

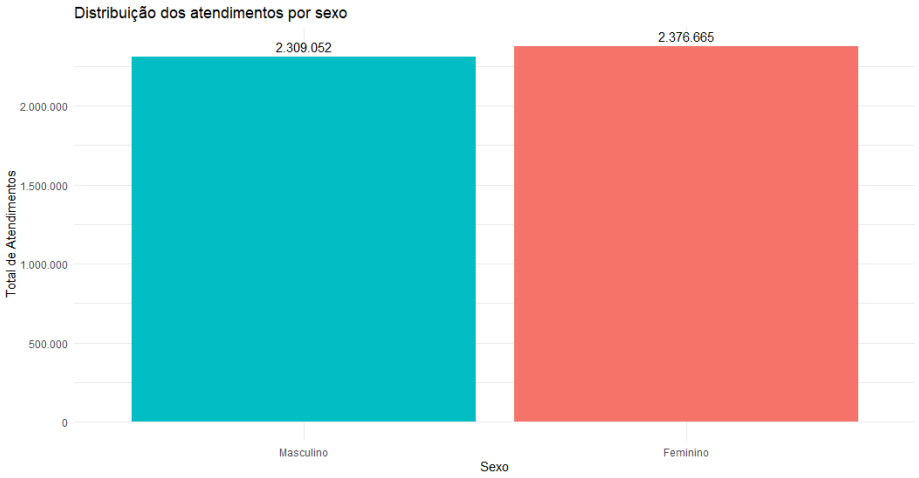
Figura 3 – Procedimento dominante por CID (10 CIDs mais frequentes)



Fonte: O autor

A análise também considerou o recorte por sexo. A Figura 4 apresenta a distribuição dos atendimentos entre pacientes do sexo masculino e feminino, revelando uma leve predominância feminina: 2.376.665 atendimentos para mulheres e 2.309.052 para homens, indicando uma possível maior adesão das mulheres aos serviços ambulatoriais do SUS.

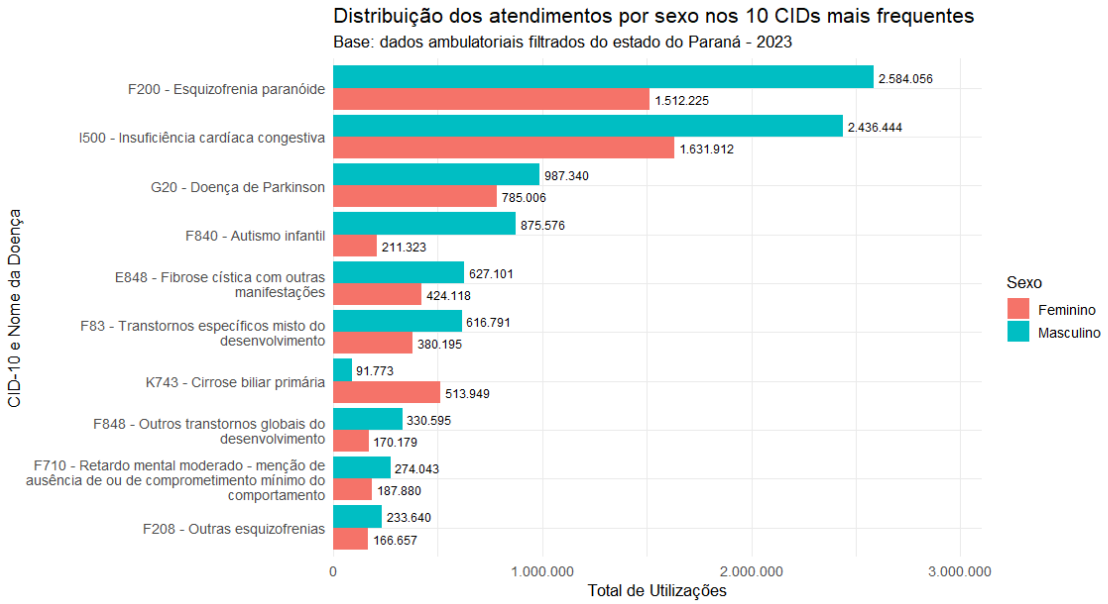
Figura 4 – Distribuição dos atendimentos por sexo



Fonte: O autor

A diferença de perfil entre os sexos se torna mais evidente quando os dados são segmentados por diagnóstico. A Figura 5 mostra que algumas condições são significativamente mais prevalentes entre os homens, como é o caso da esquizofrenia paranóide (F20.0), com 2.584.056 registros masculinos contra 1.512.225 femininos. O mesmo padrão é observado em outros transtornos do neurodesenvolvimento, como Autismo Infantil (F84.0), Transtornos mistos do desenvolvimento (F83), Retardo mental moderado (F71.0) e Doença de Parkinson (G20). Por outro lado, doenças como a Cirrose Biliar Primária (K74.3) e a Fibrose Cística (E84.8) apresentaram leve predominância entre mulheres. A insuficiência cardíaca congestiva (I50.0) também manteve a tendência de maior ocorrência no sexo masculino.

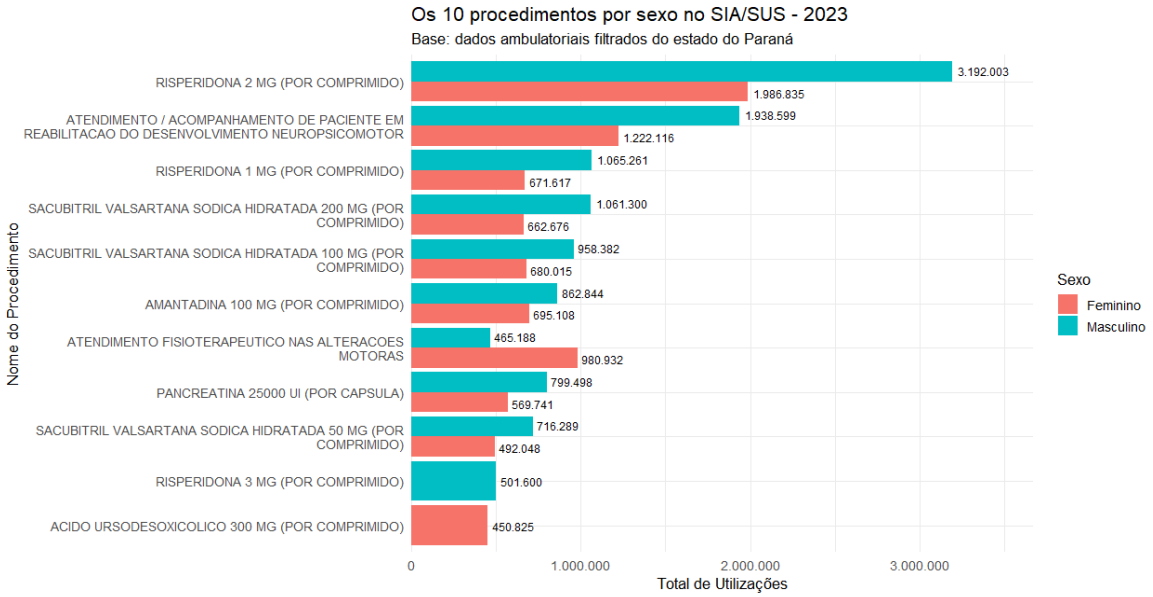
Figura 5 – Distribuição dos atendimentos por sexo nos 10 CIDs mais frequentes



Fonte: O autor

Essas diferenças de perfil também se refletem nos procedimentos realizados, conforme ilustrado na Figura 6, que apresenta os dez procedimentos ambulatoriais mais frequentes por sexo. A Risperidona 2 mg permanece como o mais utilizado entre os homens, enquanto o acompanhamento em reabilitação neuropsicomotora aparece em ambos os sexos, mas com leve predominância masculina. Procedimentos como a prescrição de Ácido Ursodesoxicólico, por outro lado, foram mais comuns entre as mulheres. Esses padrões revelam que o perfil terapêutico ambulatorial está diretamente relacionado às características demográficas dos pacientes e aos diagnósticos registrados.

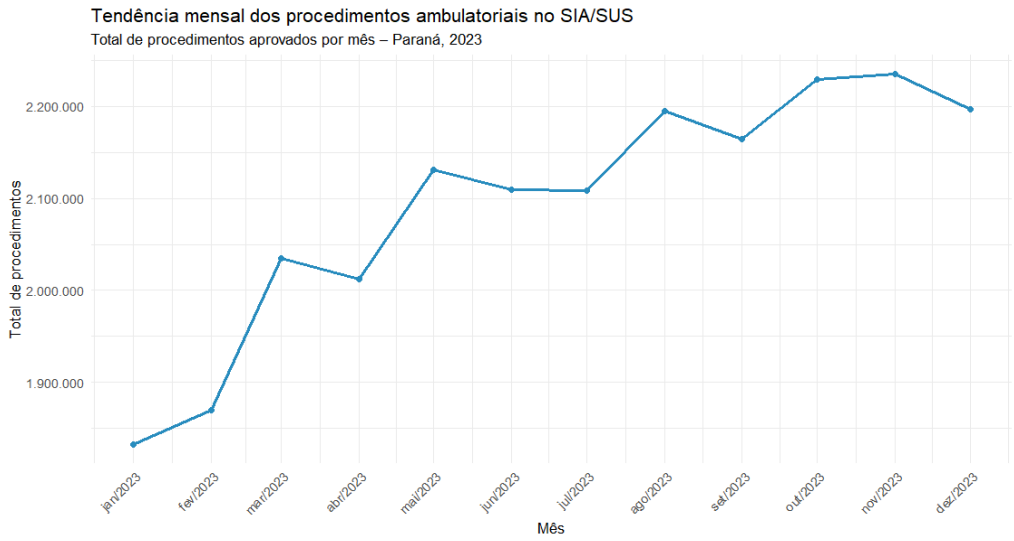
Figura 6 – Os 10 procedimentos por sexo no SIA/SUS - 2023



Fonte: O autor

No aspecto temporal, a Figura 7 apresenta a evolução mensal do número de procedimentos ambulatoriais realizados ao longo de 2023. Observa-se um crescimento contínuo durante o primeiro semestre, ultrapassando 2,1 milhões de procedimentos em maio. Nos meses de junho e julho, o volume se manteve estável, seguido de um novo aumento a partir de agosto, com pico em novembro (acima de 2,2 milhões). Em dezembro, houve uma leve redução. Essa tendência aponta maior concentração de produção ambulatorial nos meses intermediários do ano, com reduções nos períodos iniciais e finais, possivelmente relacionadas a férias, reestruturações operacionais ou limitações orçamentárias.

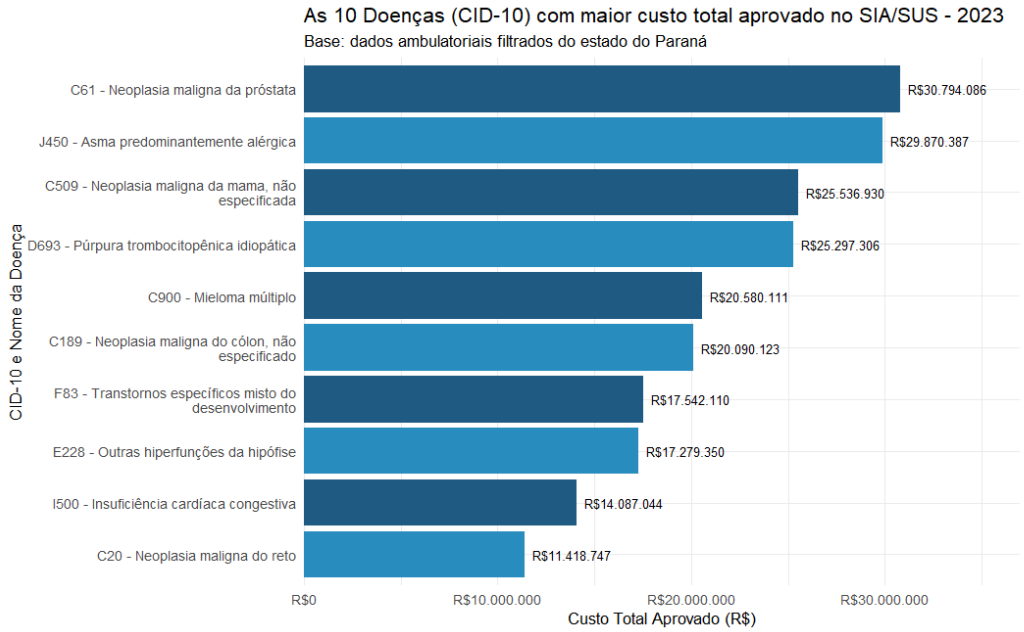
Figura 7 – Tendência mensal dos procedimentos ambulatoriais no SIA/SUS



Fonte: O autor

Por fim, a Figura 8 detalha os dez diagnósticos com maior custo total aprovado no SIA/SUS no estado do Paraná em 2023. O maior custo foi atribuído à neoplasia maligna da próstata (C61), com mais de R$30,7 milhões, seguida pela asma predominantemente alérgica (J45.0), com aproximadamente R$29,8 milhões.

Figura 8 – As 10 Doenças (CID-10) com maior custo total aprovado no SIA/SUS - 2023



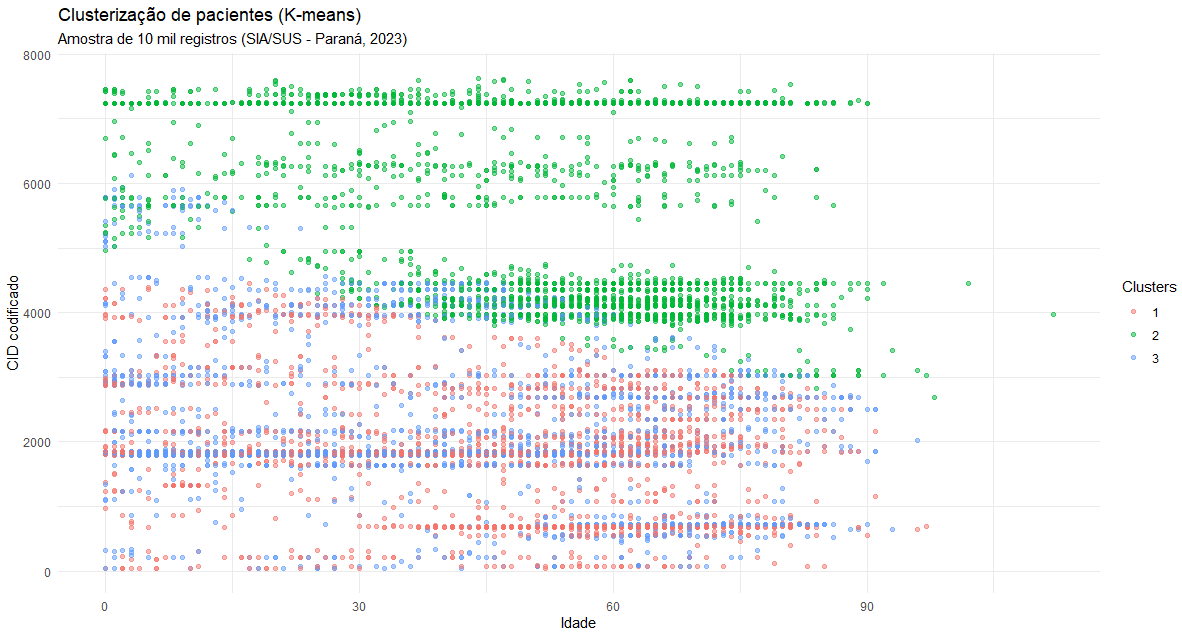
Fonte: O autor

Também, aparecem entre os principais custos as neoplasias da mama (C50.9), cólon (C18.9) e reto (C20), além de condições hematológicas como o mieloma múltiplo (C90.0) e a púrpura trombocitopênica idiopática (D69.3). Apesar de sua elevada frequência, a insuficiência cardíaca congestiva (I50.0) aparece apenas na nona posição, o que pode ser explicado pelo baixo valor unitário médio dos procedimentos associados.

4.2. Segmentação de Pacientes com K-means

A aplicação do algoritmo de agrupamento K-means em uma amostra de 10 mil registros ambulatoriais permitiu identificar padrões com base nas variáveis idade, sexo e diagnóstico (CID-10). A distribuição dos pontos no gráfico de dispersão (Figura 9) revelou uma separação visível entre os três clusters definidos, sugerindo perfis distintos de pacientes.

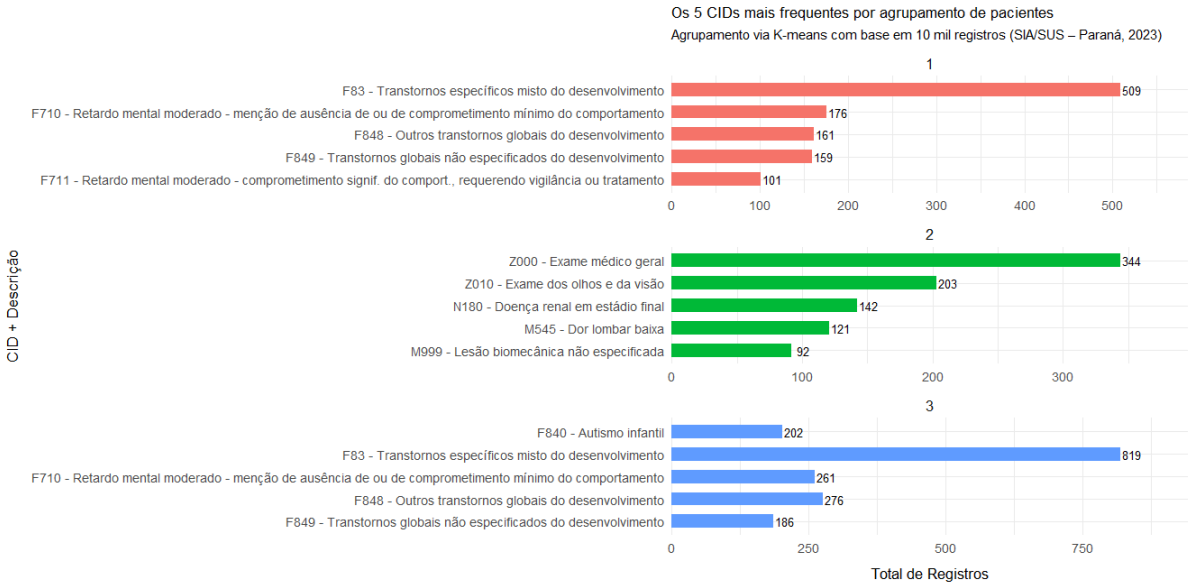
Figura 9 – Clusterização de pacientes (K-means)



Fonte: O autor

A análise dos CIDs mais frequentes por grupo (Figura 10) evidencia a predominância de diagnósticos específicos em cada cluster, permitindo uma interpretação clínica e epidemiológica dos perfis. O Cluster 1 apresentou grande concentração de transtornos do desenvolvimento, como F83 (Transtornos específicos misto do desenvolvimento), F710 (Retardo mental moderado) e F848 (Outros transtornos globais do desenvolvimento), indicando um grupo composto majoritariamente por pacientes com condições neuropsicomotoras.

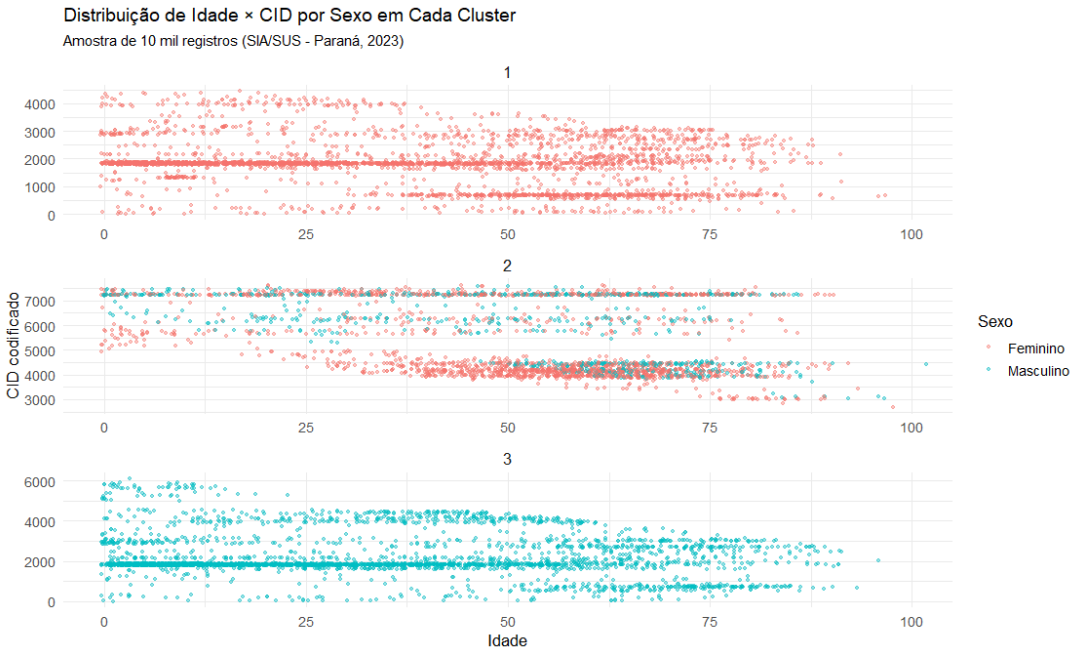
Figura 10 – Os 5 CIDs mais frequentes por agrupamento de pacientes



Fonte: O autor

O Cluster 2, por sua vez, é composto por diagnósticos mais gerais e relacionados ao cuidado contínuo e exames periódicos, como Z000 (Exame médico geral) e Z010 (Exame dos olhos e da visão), além de doenças crônicas, como N180 (Doença renal em estágio final) e M545 (Dor lombar baixa). Esse agrupamento pode ser associado a pacientes em acompanhamento ambulatorial constante, principalmente adultos e idosos com múltiplas comorbidades.

Figura 11 – Relação entre idade, CID e sexo nos clusters

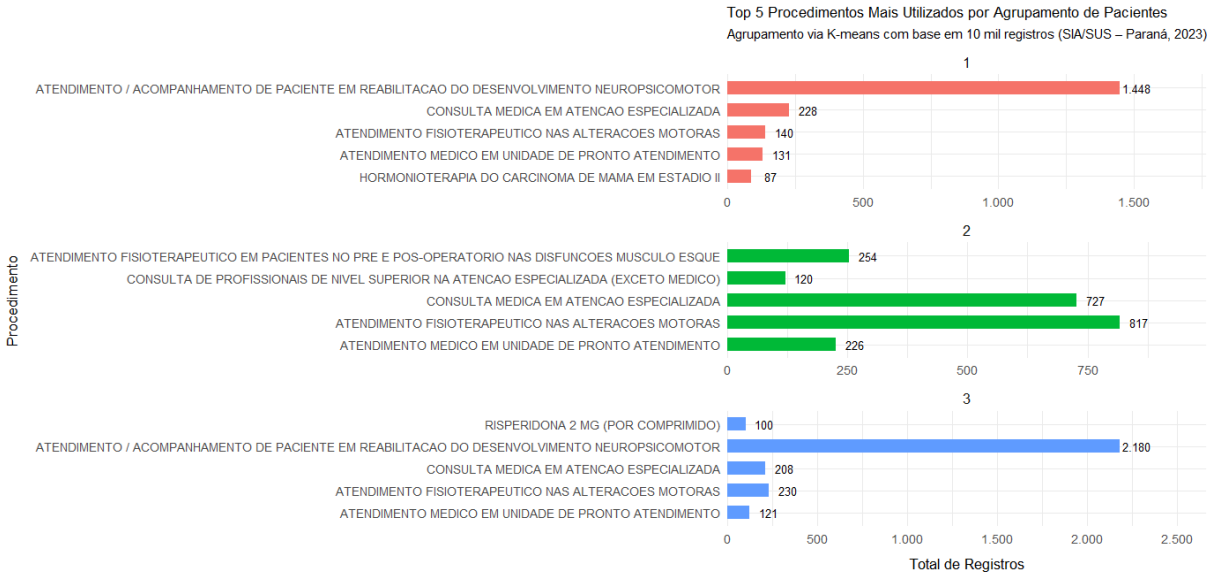


Fonte: O autor

O Cluster 3 concentrou diagnósticos como F840 (Autismo Infantil), F83, F710 e F849 (Transtornos não especificados do desenvolvimento), caracterizando um perfil fortemente associado à infância e adolescência, com foco em condições do espectro autista e atrasos no desenvolvimento.

A distribuição por sexo e idade em cada agrupamento (Figura 11) reforça essas interpretações. O Cluster 1 é majoritariamente feminino, com ampla distribuição etária, sugerindo um perfil diversificado de pacientes com condições de desenvolvimento e hormonais. O Cluster 2 apresenta maior concentração de idosos de ambos os sexos, enquanto o Cluster 3 é composto predominantemente por pacientes do sexo masculino, com maior concentração na faixa etária da infância e adolescência.

Figura 12 – Os 5 procedimentos mais utilizados por agrupamento de pacientes



Fonte: O autor

Complementarmente, a análise dos procedimentos mais frequentes por cluster (Figura 12) reforça o perfil funcional de cada grupo. O Cluster 1 é fortemente associado ao procedimento "Atendimento em Reabilitação do Desenvolvimento Neuropsicomotor", indicando foco em cuidados multidisciplinares. O Cluster 2 concentra procedimentos como consultas médicas especializadas, atendimento fisioterapêutico e atenção primária, representando cuidados de manutenção à saúde em casos crônicos. Por fim, o Cluster 3, apesar de também apresentar registros de reabilitação, se destaca por procedimentos como o uso de risperidona em solução oral e acompanhamento neuropsicológico, alinhando-se ao tratamento medicamentoso e terapêutico de transtornos mentais e do neurodesenvolvimento.

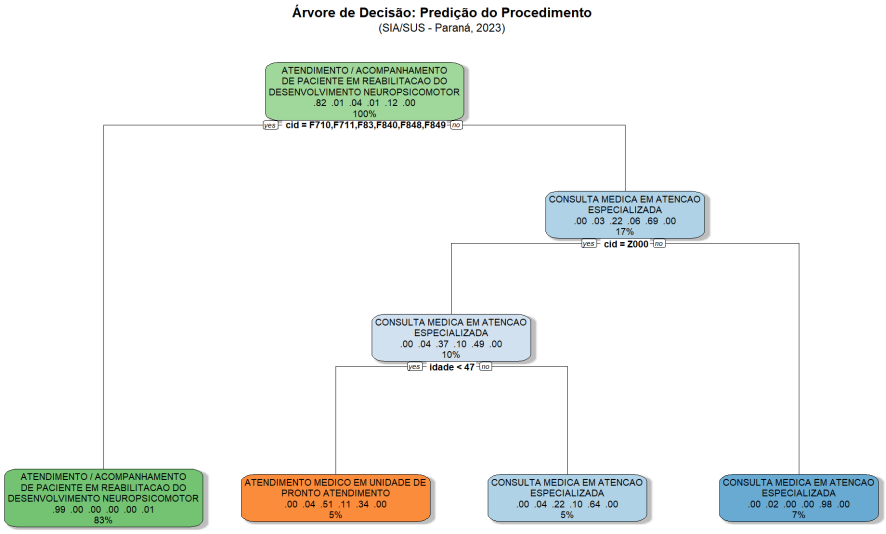
4.3. Predição e Associação entre Diagnósticos (CID-10) e Procedimentos (SIGTAP)

A árvore de decisão aplicada identificou padrões claros entre diagnósticos e procedimentos. O modelo, baseado nos oito CIDs e procedimentos mais frequentes, destacou o procedimento "Atendimento / Acompanhamento de Paciente em Reabilitação do Desenvolvimento

Neuropsicomotor", corretamente classificado em 83% dos casos no nó correspondente (Figura 13). Esses registros estavam majoritariamente associados aos CIDs F710, F711, F83, F840, F848 e F849, relacionados a transtornos do neurodesenvolvimento.

O CID Z000 (Exame médico geral) também se destacou como forte indicador de "Consulta Médica em Atenção Especializada", especialmente em pacientes com idade acima de 47 anos. A idade influenciou diretamente a separação entre consultas gerais e atendimentos de urgência, como "Atendimento Médico em Unidade de Pronto Atendimento".

Figura 13 – Árvore de Decisão: Predição dos Procedimentos



Fonte: O autor

Figura 14 – Algoritmo Apriori

	CID	Procedimento	support	confidence	lift	count
1	M545	ATENDIMENTO FISIOTERAPEUTICO NAS ALTERACOES MOT...	0.04167333	0.8585949	20.602981	12502
2	N180	CONSULTA DE PROFISSIONAIS DE NIVEL SUPERIOR NA ATE...	0.01203333	0.4905558	19.735381	3610
3	Z000	ATENDIMENTO MEDICO EM UNIDADE DE PRONTO ATENDI...	0.03333667	0.3359874	9.143343	10001
4	Z010	CONSULTA MEDICA EM ATENCAO ESPECIALIZADA	0.06159000	0.9772571	7.973053	18477
5	N180	CONSULTA MEDICA EM ATENCAO ESPECIALIZADA	0.01244333	0.5072700	4.138615	3733
6	Z000	CONSULTA MEDICA EM ATENCAO ESPECIALIZADA	0.04378333	0.4412753	3.600190	13135
7	F83	ATENDIMENTO / ACOMPANHAMENTO DE PACIENTE EM RE...	0.35376333	0.9986168	1.322531	106129
8	F710	ATENDIMENTO / ACOMPANHAMENTO DE PACIENTE EM RE...	0.11450667	0.9983725	1.322208	34352
9	F849	ATENDIMENTO / ACOMPANHAMENTO DE PACIENTE EM RE...	0.07441000	0.9955403	1.318457	22323
10	F711	ATENDIMENTO / ACOMPANHAMENTO DE PACIENTE EM RE...	0.06075667	0.9940012	1.316418	18227
11	F848	ATENDIMENTO / ACOMPANHAMENTO DE PACIENTE EM RE...	0.10185333	0.9923357	1.314213	30556
12	F840	ATENDIMENTO / ACOMPANHAMENTO DE PACIENTE EM RE...	0.04979000	0.8698969	1.152059	14937

Fonte: O autor

Já o algoritmo Apriori revelou regras de associação relevantes entre CID e procedimento (Figura 14). O maior lift (20,6) foi observado entre o CID M545 (Dor lombar baixa) e o atendimento fisioterapêutico, evidenciando o padrão de reabilitação física. O CID Z000 também aparece associado tanto à consulta quanto ao pronto atendimento, indicando sua presença recorrente em diferentes contextos ambulatoriais.

5. Considerações Finais

O presente estudo teve como objetivo analisar os padrões de uso de medicamentos e terapias registrados no Sistema Único de Saúde (SUS), com foco nos atendimentos realizados no estado do Paraná ao longo do ano de 2023. A partir da aplicação de técnicas de mineração de dados sobre uma base consolidada de mais de 4,6 milhões de registros do SIA/SUS, foi possível identificar tendências relevantes e perfis distintos de utilização dos serviços de saúde pública.

A análise exploratória revelou a elevada incidência de procedimentos associados à saúde mental e ao neurodesenvolvimento, com destaque para o uso expressivo da Risperidona 2 mg e para o diagnóstico de esquizofrenia paranoide (CID F20.0), indicando um cenário de atenção contínua aos transtornos psiquiátricos e comportamentais. Além disso, os dados demonstraram diferenças significativas por sexo, idade e faixa etária, sugerindo perfis de usuários com demandas específicas em determinadas áreas terapêuticas.

A segmentação de pacientes por meio do algoritmo K-means permitiu identificar três agrupamentos principais, com características clínicas e demográficas distintas, facilitando a compreensão dos padrões de atendimento e possíveis direcionamentos estratégicos. A árvore de decisão, por sua vez, demonstrou a capacidade preditiva das variáveis idade, sexo e CID-10 na indicação do procedimento realizado, com destaque para o atendimento em reabilitação do desenvolvimento neuropsicomotor. Por sua vez, as regras de associação extraídas com o algoritmo Apriori evidenciaram relações robustas entre diagnósticos e procedimentos, como a associação entre dor lombar baixa e atendimento fisioterapêutico.

Os resultados obtidos reforçam a importância do uso de ferramentas computacionais no apoio à gestão do SUS, permitindo não apenas a detecção de padrões e comportamentos assistenciais, mas também a identificação de possíveis excessos, desperdícios ou concentrações de recursos. O uso de bases públicas, padronizadas e de amplo escopo, como o SIA/SUS e o SIGTAP, demonstra ser uma estratégia viável e replicável para a produção de conhecimento aplicável à saúde coletiva.

Com os resultados deste estudo, surgem diferentes possibilidades para pesquisas futuras. Uma delas é ampliar o recorte temporal, incorporando dados de anos anteriores ou mais recentes. Assim, seria possível acompanhar a evolução dos atendimentos, avaliar os efeitos de políticas públicas e observar a influência de eventos como crises sanitárias ou variações sazonais na demanda.

Outra linha de investigação consiste em expandir o estudo para outros estados ou regiões do país, permitindo comparações entre contextos distintos do SUS. Essa abordagem ajudaria a

identificar desigualdades regionais, boas práticas locais e diferenças nos padrões de uso de medicamentos e terapias.

Por fim, se aponta como caminho promissor a criação de dashboards interativos. Com eles, gestores, profissionais e pesquisadores poderiam explorar os dados de maneira simples e personalizada, utilizando filtros dinâmicos, mapas de calor, séries temporais e gráficos de associação para interpretar grandes volumes de informação.

Referências

AMARAL, T. M. *Mineração de dados na saúde pública*. Curitiba: Appris, 2019.

AWARI. *Etapas essenciais do processo de mineração de dados*. Disponível em: https://awari.com.br/processo-de-mineracao-de-dados-etapas-essenciais-para-extrair-informacoes-valiosas/. Acesso em: 16 set. 2025.

BASE DOS DADOS. *Conjuntos de dados abertos*. Disponível em: https://basedosdados.org. Acesso em: 16 set. 2025.

BRASIL. Ministério da Saúde. *DATASUS - Sistema de Informações Ambulatoriais*. Disponível em: http://sia.datasus.gov.br. Acesso em: 16 set. 2025.

BRASIL. Ministério da Saúde. *DATASUS - Sistema de Informações Hospitalares*. Disponível em: http://sihd.datasus.gov.br. Acesso em: 16 set. 2025.

BRASIL. Ministério da Saúde. Departamento de Informática do SUS – DATASUS. *Informações de saúde (TABNET)*. Disponível em: https://datasus.saude.gov.br. Acesso em: 5 jul. 2025.

BRASIL. Ministério da Saúde. Departamento de Informática do SUS – DATASUS. *Sobre o DATASUS*. Disponível em: https://datasus.saude.gov.br/sobre-o-datasus/. Acesso em: 16 set. 2025.

BRASIL. Ministério da Saúde. *SIGTAP - Sistema de Gerenciamento da Tabela de Procedimentos, Medicamentos e OPM do SUS*. Disponível em: http://sigtap.datasus.gov.br. Acesso em: 16 set. 2025.

CARVALHO, Hialo Muniz. *Aprendizado de máquina voltado para mineração de dados: árvores de decisão*. Monografia (Graduação)–UnB, p. 98, 2014.

GARCIA, Simone C. *O uso de árvores de decisão na descoberta de conhecimento na área da saúde*. 2003.

HAN, J.; KAMBER, M.; PEI, J. *Data mining: concepts and techniques*. 3. ed. San Francisco: Morgan Kaufmann, 2012.

IBGE. *Comitê de Estatísticas Sociais*. Disponível em: https://ces.ibge.gov.br. Acesso em: 16 set. 2025.

LAVRAČ, N. Selected techniques for data mining in medicine. *Artificial Intelligence in Medicine*, v. 16, n. 1, p. 3–23, 1999.

MÁRQUEZ-VERA, C. et al. *Predicting student failure at school using genetic programming and different data mining approaches with high dimensional and imbalanced data*. Applied Intelligence, v. 38, n. 3, p. 315-330. Abr. 2013.

PORTELA, Margareth Crisóstomo et al. *Algoritmo para a composição de dados por internação a partir do sistema de informações hospitalares do sistema único de saúde (SIH/SUS)-Composição de dados por internação a partir do SIH/SUS.* Cadernos de Saúde Pública, v. 13, p. 771-774, 1997.

ROSSINI, Luiz Amelio Sodaite et al. *DATA MINING: conceitos e consequências*. Revista Interface Tecnológica, v. 15, n. 2, p. 50-59, 2018.

SANTANA, Roniel Venâncio; PONTES, Heráclito Lopes Jaguaribe. *Aplicação da Clusterização por K-means para Criação de Sistema de Recomendação de Produtos baseado em Perfis de Compra*. Navus: Revista de Gestão e Tecnologia, n. 10, p. 31, 2020.

SILVA, A. A.; PERES, M. S.; BOSCARIOLI, C. *Mineração de dados: conceitos, técnicas, algoritmos e aplicações.* São Paulo: Novatec, 2016.

SILVA, Glauco Carlos. *Mineração de regras de associação aplicada a dados da Secretaria Municipal de Saúde de Londrina PR*. 2004.

STEMMER, Luis Henrique Goulart et al. *Desenvolvimento de Ferramenta de Análise e Mineração de Dados de Suicídio do DATASUS*. 2023.

UNA-SUS. *Universidade Aberta do SUS. Registros e estatísticas do SUS*. Disponível em: https://www.unasus.gov.br. Acesso em: 5 jul. 2025.

WORLD HEALTH ORGANIZATION. *Global strategy on digital health 2020–2025*. Geneva: WHO, 2022. Disponível em: https://www.who.int/publications/i/item/9789240020924. Acesso em: 5 jul. 2025.